

UNIVERSITÉ GRENOBLE ALPES
UFR SCIENCES DE L'HOMME ET DE LA SOCIÉTÉ

Modélisation Computationnelle de Recherche Lexicale

Matière :
Cognition et apprentissage (UE COG f5)

Auteurs :

Ramez DAHOUATHI
Alexandre CHOLAT

Enseignant :

M. Benoît LEMAIRE

Année universitaire 2025-2026

Janvier 2026

Table des matières

1	Contexte	2
2	Description du modèle théorique	3
3	Description de la version computationnelle	3
3.1	Bloc A : Extraction des paramètres	3
3.2	Bloc B : Le Simulateur	3
4	Description de l'expérience de recueil de données	4
5	Données expérimentales	5
6	Données simulées	7
7	Évaluation du modèle	7
8	Résultats et interprétation	9
9	Limites et intérêts	9

1 Contexte

Nous nous sommes demandé comment les gens parcouraient un dictionnaire. Quelles caractéristiques d'un mot le rendent plus ou moins coûteux à chercher ? Et quelles trajectoires emprunter pour le trouver ? Pour formuler une hypothèse, nous sommes allés à la bibliothèque pour observer la recherche en dictionnaire. Est-ce que les gens le parcourent page par page ? Lisons-nous chaque mot ou par recherche binaire ? Ni l'un ni l'autre. Nous avons observé deux étapes principales pour la recherche d'une cible. La première est l'estimation de la section du dictionnaire contenant la première lettre du mot cible. La deuxième étape de cette recherche est celle de comparaison des valeurs hiérarchiques des séquences de lettre par rapport à celles du mot cible. Nous avons observé que les utilisateurs parcourent la page rapidement avant de passer à la suivante, ralentissant seulement pour lire les mots individuels une fois qu'ils se rapprochent de la cible. Il est également à noter que il est commun de dépasser la cible avant de se rendre compte et reculer, entraînant un comportement de réduction de vitesse de recherche. Il s'agit cependant d'observations préliminaires et aucune conclusion définitive n'a encore été tirée.

Alors, qu'essayons-nous de mesurer ? Le temps est définitivement l'objectif principal, ce qui en fait notre variable dépendante (VD). Quant à ce qui pourrait influencer le temps nécessaire pour atteindre le mot cible, de nombreuses variables au sein d'un mot pourraient jouer un rôle, telles que la position alphabétique, la densité du préfixe et la longueur du mot. Nous avons choisi la fréquence des mots plutôt que la longueur des mots parce que la recherche montre que pour les mots familiers, le cerveau utilise une « voie lexicale » sensible à la fréquence mais largement indépendante de la longueur (Coltheart et al., 2001). Dans une tâche de recherche dans un dictionnaire, les utilisateurs recherchent des formes « connues », ce qui fait de la fréquence un indicateur plus important du temps de recherche.

Au-delà de fréquence, d'autres facteurs jouent dans les patterns de recherche sémantique. La polarisation est la distance normalisée de l'indice du mot de départ par rapport à la position du mot cible. La polarisation est à la fois une représentation de la première lettre du mot, car les mots partageant le même préfixe sont organisés séquentiellement, en plus de la distance absolue à parcourir jusqu'à la cible. Cette pertinence de la position est établie sur la recherche et navigation séquentielle. La littérature sur la recherche sérielle auto-terminante indique que le temps de recherche est une fonction linéaire de la position de la cible (Neisser, 1963).

Ceci nous mène à la formulation des hypothèses suivantes :

- La fréquence de récupération lexicale d'un mot aura un impact sur la temps de recherche de position de celui-ci dans un dictionnaire.
- La polarisation d'un mot relatif à la position de départ de recherche aura un impact sur la temps de recherche de position de celui-ci dans un dictionnaire.
- La polarisation d'un mot relatif à la position de départ de recherche et sa fréquence de récupération lexicale auront un effet d'interaction sur la temps de recherche.

2 Description du modèle théorique

Enfin, les participants ne recherchent pas le mot de manière linéaire ni aléatoire. Au lieu de cela, ils utilisent une stratégie hybride qui consiste en une phase balistique où les participants utilisent leurs connaissances de l'ordre alphabétique pour aider à viser la zone probable du scroller. Le temps de ce saut dépend de la distance D selon la loi de Fitts qui est une fonction logarithmique qui suggère que la distance physique séparant le point de départ de la cible est un prédicteur du temps d'acquisition. Pourquoi logarithmique ? Parce que l'humain traite l'information spatiale de manière logarithmique car plus il se rapproche de la cible, plus il a besoin de précision. Dans un deuxième temps, la phase d'ajustement une fois dans la bonne zone, les participants affinent leur recherche. Les humains ne lisent pas les mots un par un (ce qui prendrait trop de temps). Ils traitent des « paquets » de mots (environ 70) d'un seul coup d'œil pour décider de continuer ou d'arrêter le défilement. On implémente aussi le mécanisme d'erreur où l'imprécision du scroll (le "Bruit") oblige l'humain à effectuer une phase de correction. Plus le bruit (sigma qui représente la variabilité innée du système moteur humain) est grand, plus le nombre de "sauts visuels" augmente pour rattraper l'erreur. La fréquence des mots influence le coût de vérification visuelle B . Selon le principe de Shannon-Fano, les objets fréquents ont une "taille de codage" mentale plus courte. Par conséquent, le cerveau les identifie plus vite, ce qui réduit le temps passé par "regard" visuel.

3 Description de la version computationnelle

Le modèle a été implémenté selon deux blocs distincts :

3.1 Bloc A : Extraction des paramètres

C'est à cette étape que s'effectue l'extraction des paramètres. Nous analysons les 229 essais réels pour établir des moyennes : par exemple, le temps nécessaire aux participants pour démarrer ou la distance d'erreur (en mots) lors du premier saut. Le code prélève ces données réelles pour calculer le temps de réaction initial (A) et la variabilité du défilement (σ). Ce processus permet de "calibrer" le modèle sur les comportements humains réels avant de lancer les simulations.

3.2 Bloc B : Le Simulateur

Nous avons opérationnalisé la « Fréquence » de la variable indépendante (VI) en attribuant un poids numérique à chaque mot (0 pour commun, 1 pour intermédiaire, 2 pour rare). Ce poids agit comme un multiplicateur de difficulté. Ainsi, ce paramètre influence directement la vitesse de traitement du modèle. Mathématiquement, le coût d'un « regard visuel » augmente de 0,25 s par niveau. Cela simule le fait que l'identification d'un objet inconnu nécessite un temps de fixation oculaire plus long.

Le Temps de mouvement : Présente la Loi de Fitts simplifiée que nous avons utilisée :

$$T_{mouv} = b \cdot \log_2 \left(\frac{D}{L} + 1 \right)$$

(Où D est la distance et L la largeur de la cible visuelle).

L’Erreur de saut : Explique l’usage de la Loi Normale (Bruit gaussien) pour simuler l’imprécision du scroll :

$$P_{atter} \sim \mathcal{N}(0, \sigma^2)$$

Le Coût de vérification : Présente l’équation finale qui intègre la fréquence et le chunking :

$$T_{verif} = Cout_{freq} \times \left(\frac{|P_{atter}|}{70} \right)$$

Le paramètre de *taille de regard* fixé à 70 mots représente la capacité de **chunking visuel** (regroupement d’informations) du système perceptif humain ; cette valeur a été retenue par **calibrage algorithmique** car elle permet de minimiser l’erreur quadratique moyenne (RMSE) entre les simulations et les données réelles, suggérant qu’un utilisateur traite environ une demi-page de dictionnaire par fixation avant de décider de la suite de sa navigation.

L’équation finale le temps simulé :

$$T_{simule} = A_{reaction} + C_{fixe} + T_{Fitts} + \left(C_{freq} \times \frac{Distance}{70} \right)$$

L’équation finale simule le temps total en additionnant le délai de réaction initial, le temps de mouvement balistique et le coût de vérification visuelle par blocs. La constante fixe de 4 secondes a été introduite comme un “temps résiduel” modélisant la vérification finale du mot et la préparation motrice du clic, permettant ainsi d’ajuster précisément le modèle pour minimiser le RMSE. Code source : L’ensemble de l’implémentation du simulateur, des calculs de RMSE et des visualisations Seaborn est disponible sur GitHub : https://github.com/Alexandre-Cholat/semantic_search_computational_model.

4 Description de l’expérience de recueil de données

La méthodologie expérimentale est la suivante : Un jeu de 12 mots est conçu à partir de données open source (Lexique.org, Lexique 3.83) pour introduire les variables indépendantes. Ce jeu est composé de 4 groupes de mots de première lettres différents (‘d’, ‘g’, ‘r’, ‘v’), dont une lettre pour evaluation, et chaque groupe de lettre de départ contient trois mots de fréquences différentes (haute fréquence, moyenne fréquence, basse fréquence). Les modalités de fréquence sont définies à partir de la table freqfilms2 du lexique : plus de 80 apparitions

pour les mots de haute fréquence, entre 1.0 et 0.15 apparitions pour les mots de moyenne fréquence, et moins de 0.01 apparitions pour les mots de basse fréquence. Les participants étaient des adultes maîtrisant la langue française. Pour garantir un échantillon diversifié, ils ont été sélectionnés parmi diverses spécialités, ethnies et origines. L'expérience est passée dans une salle tranquille, assis dans une chaise face à un ordinateur portable placé sur une table. Chaque mot cible est présenté individuellement au participant via une interface, avec instruction d'aller à la position du mot cible dans un dictionnaire, et la trajectoire de recherche est enregistrée. Le participant est présenté l'intégralité des mots cibles, d'ordre aléatoire.

Pour implémenter le protocole de recueil de l'expérience, une interface numérique a été conçue. Celle-ci a pour objectif de simuler la tâche de recherche en dictionnaire, et de recueillir les informations spatiales et temporelles des déplacements dans une dimension.

L'interface graphique a été construite via la bibliothèque Tkinter en Python. Pour isoler la tâche cognitive de comparaison de mots selon hiérarchie alphabétique, seulement un mot est affiché à la fois. Une séquence de 5000 mots, représentatifs de la distribution d'un dictionnaire français. Celle-ci est dérivée d'un lexique open source Freelang. (2025) de 22,000 mots, qui a été nettoyée et échantillonnée aléatoirement pour réduire la taille.

Dessus l'affichage du mot correspondant à l'indice de position actuelle, l'interface graphique est composée de quatre boutons : "Suivant" et "Précédent" permettant un déplacement unitaire, et "Démarrer" et "Trouvé" pour signaler le début et la fin du temps de recherche d'un mot. Une barre de défilement (appelée un scroller) est également disponible en complément des boutons de déplacement unitaire, permettant un déplacement par saut d'indice rapide et simulant l'estimation approximative d'index de début de recherche lors de l'ouverture d'un dictionnaire physique. L'interface est totalement capable de gérer des entrées interdites, telles que cliquer sur "Trouvé" en étant sur le mauvais mot. A l'initiation d'une expérience, un fichier csv contenant le numéro de participant anonymisée est enregistré. Au fil de l'expérience, une liste de paires temps-position est créée, correspondant à chaque mot cible. Une paire temps-position est ajoutée à la liste si le participant s'arrête pour plus d'une seconde sur un indice de position, ou bien s'il change de direction de déplacement.

Suite à l'enregistrement des données en format csv, les données sont prêtes pour le stockage. Pour pouvoir effectuer un grand nombre d'expériences, il était primordial d'employer une pipeline de stockage basée sur cloud, permettant une passation d'expérience en parallèle. Un script d'automatisation de téléversement vers une plateforme de stockage sur cloud, Supabase, est appelé via API. La plateforme cloud s'occupe de stockage objet (via un bucket) et insertion des données dans une table relationnelle, éliminant ainsi le besoin d'une infrastructure serveur locale.

5 Données expérimentales

Une fois toutes expériences passées, le téléchargement de données agrégées sur cloud vers une machine locale permet l'analyse et la construction d'un modèle.

Cependant une première phase de nettoyage est nécessaire. Le fichier de données brutes

en csv est d'abord inspecté pour identification de valeurs aberrantes et expériences mal exécutées. L'oubli de la sélection du bouton "Démarrer" par exemple, ou des expériences dépassant 60 secondes, produisent des données intéressantes qui pourraient perturber le modèle. Un script python de nettoyage élimine des paires position-temps d'où plusieurs valeurs de position sont enregistrées pour le même instant.

Nous pouvons faire une première analyse des données expérimentales en segmentant le jeu de données selon les trois niveaux de fréquence. Pour chacun de ces groupes, une analyse de variance ANOVA à un facteur est effectuée pour évaluer l'impact de la lettre initiale ('d', 'g', 'r', 'v'), représentant la polarisation, sur le temps de recherche, que l'on visualise ci-dessous [Fig. 1]. Pour les groupes de fréquence moyenne et basse, l'ANOVA à un facteur met en




FIGURE 1 – 3 ANOVAs 1 facteur

évidence un effet principal significatif de la lettre initiale sur le temps de recherche ($p < 0,05$). Cela indique que pour les mots moins familiers, la polarisation influence directement la performance de recherche. Il est très intéressant à noter l'absence d'effet significatif pour les mots de haute fréquence.

Le phénomène d'absence de lien entre polarisation et temps de recherche pour les mots de haute fréquence observé a inspiré la conception d'un modèle, nommé 'Modèle 1 : Théorique' dans les figures de comparaison, et utilise la fréquence comme variable pour dériver les paramètres statistiques (moyenne et écart-type) d'une distribution normale asymétrique. Pour capturer le comportement observé expérimentale, ce modèle calcule une distribution spécifique pour chaque catégorie de fréquence, en utilisant des paramètres comportementaux distincts. Ces fonctions de densité de probabilité individuelles sont ensuite pondérées par leur occurrence réelle dans les données expérimentales et fusionnées pour former un « modèle de

mélange » (*MixtureModel*).

Ce modèle atteint ses meilleures performances [Fig. 2a] pour les fréquences de modalités hautes, correspondant au résultat de l'analyse ANOVA. Le modèle produit un RMSE de seulement 2.49 sous condition de prédiction de mots de haute fréquence. Cependant, les performances diminuent légèrement, produisant un RMSE de 3.53, soit une plus grosse erreur de prédiction, pour des fréquences de mots plus basses [Fig. 2b].


Suivant le nettoyage, les données sont prêtes pour l'analyse et la construction d'un modèle. Cependant, nous voulons d'abord séparer les données d'entraînement et d'évaluation, pour pouvoir tester les capacités de généralisation. Un script de 'split' sépare tous mots commençant par la lettre 'g' des données, séparant en deux dataframes et enregistrant les jeux de données sous form .pkl sur machine locale.

6 Données simulées


La phase de simulation consiste à générer 229 essais synthétiques en utilisant les caractéristiques de polarisation et de fréquence de chaque essai humain comme variables d'entrée. Le modèle transforme ces entrées en temps de recherche en s'appuyant sur des paramètres extraits statistiquement des données réelles. Le paramètre A (temps de réaction initial) agit comme une ligne de base temporelle : une valeur de A plus élevée décalerait l'ensemble de la distribution vers la droite, simulant une hésitation cognitive accrue avant le début de la recherche. Le paramètre σ (bruit gaussien), quant à lui, pilote la précision du saut initial. Une augmentation de σ signifierait une plus grande imprécision motrice, forçant le modèle à effectuer davantage de « sauts visuels » de correction, ce qui aplatiserait la courbe de densité et augmenterait la dispersion des temps de recherche. À l'inverse, un σ réduit traduirait une navigation spatiale très précise, concentrant les résultats simulés autour de la performance optimale. Par ce mécanisme stochastique, la simulation ne produit pas un temps fixe mais une distribution de probabilité qui reflète la variabilité naturelle du comportement humain face à la difficulté lexicale.

7 Évaluation du modèle

Suite à l'affinage du modèle par comparaison aux données expérimentales d'entraînement, il est pertinent d'évaluer ces performances sur des données non présentes en phase de validation et quantifier les compétences de généralisation de la production. Un script python applique le modèle au jeu de données expérimentales 'test', représentant les données expérimentales pour trois mots de fréquences différentes, commençant par 'g'. Les prédictions du modèle sont générées pour chaque instance d'expérience réelle, avec les nouveaux paramètres de polarisation et de fréquence correspondant. Les prédictions du modèle computationnel, ainsi que la courbe du modèle théorique prenant uniquement la fréquence en paramètre, sont superposées au nouveau jeu de données expérimentales [Fig. 3]. La RMSE de chaque modèle est calculée.



(a) Résultat d'évaluation de Modèle 1 pour haute fréquence visualisé.



(b) Résultat d'évaluation de Modèle 1 pour basses fréquence visualisé.

FIGURE 2 – Résultats d'évaluation de Modèle 1 selon la fréquence.




FIGURE 3 – Résultats d'évaluation de modèles et comparaison visualisées.

8 Résultats et interprétation

Le modèle 2 de simulation computationnelle produit une RMSE de 3.3. Le modèle 1 produit une RMSE de 4.86, soit une erreur 47% plus importante que le modèle 2.

Le modèle 2, prenant en compte la polarisation, en plus de la fréquence, atteint un plus faible taux d'erreur que le modèle basé uniquement sur les fréquences. Ceci révèle la double l'importance de la première lettre d'un mot sur le temps de recherche pour la tâche de recherche d'une cible dans un dictionnaire. Il est à noter que l'effet de polarisation est de plus faible magnitude que l'effet de fréquence.

Cela confirme l'hypothèse que nous naviguons légèrement plus rapidement vers certaines plages du dictionnaires que d'autres. Pourquoi ? Nous pensons que notre représentation spatiale de la distribution des lettres dans le dictionnaire est plus précise pour certaines lettres. Le fait que certaines lettres (comme le 'd') facilitent la recherche par rapport à d'autres (comme le 'v') indique que notre représentation mentale de l'alphabet n'est pas uniforme. Les utilisateurs semblent posséder une représentation spatiale du dictionnaire plus précise pour les sections initiales, ce qui réduit le paramètre de bruit.

9 Limites et intérêts

Le modèle ne se contente pas de décrire les événements observés ; il est capable de prédire le temps de recherche de nouveaux mots (non testés par les participants) sur la seule base

de leur position et de leur fréquence. Au-delà de cette capacité prédictive, le modèle se distingue par sa robustesse et sa simplicité. En intégrant des mécanismes tels que la loi de Fitts et le traitement par blocs (chunking), nous parvenons à simuler la distribution des temps de recherche de 20 participants avec une grande précision. Le RMSE d'environ 3 secondes atteste de cette fidélité, prouvant que quelques règles élémentaires suffisent à capturer la complexité de 229 essais humains. Aucun modèle n'est parfait. L'algorithme traite le premier et le douzième mot de manière identique alors qu'en réalité, un humain peut gagner en rapidité (apprentissage de l'interface) ou ralentir (fatigue, baisse d'attention) au cours de l'expérience. Par ailleurs, le modèle postule que l'utilisateur finit toujours par trouver le mot ; il ne simule donc pas les abandons, les erreurs de clic ou les faux positifs (lorsqu'un mot ressemblant est sélectionné par mégarde). Enfin, une limitation importante de notre version computationnelle réside dans le réglage du paramètre b de la loi de Fitts. Ce paramètre est actuellement une estimation fixe (0,5) visant à donner au temps de mouvement initial un ordre de grandeur cohérent. Une étude spécialisée permettrait de mesurer les performances motrices réelles des participants sur cette interface spécifique. Une telle mesure affinerait la précision du modèle en remplaçant cette constante par une valeur issue d'une régression linéaire sur les temps de mouvement observés.

Bibliographie

- Coltheart M, Rastle K, Perry C, Langdon R, Ziegler J. DRC : a dual route cascaded model of visual word recognition and reading aloud. *Psychol Rev.* 2001 Jan ;108(1) :204–56. doi : 10.1037/0033-295X.108.1.204. PMID : 11212628.
- Ferrand, L. & New, B. (2003). Syllabic length effects in visual word recognition and naming, *Acta Psychologica*, 113, 167–183.
- Neisser U. (1963) Decision-time without reaction-time : Experiments in visual scanning. *American Journal of Psychology* 76 : 376–385
- Freelang. (s.d.). Dictionnaire français [5000 mots]. Récupéré le 14 janvier 2026, de <https://www.freelang.com/dictionnaire/dic-francais.php>
- New, B., Pallier, C., Brysbaert, M., & Ferrand, L. (2004). Lexique 2 : Une nouvelle base de données pour le français. *L'Année psychologique*, 104(3), 421–451. <http://www.lexique.org>
- Waskom, M. L. (2021). seaborn : statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>